

CS310 Natural Language Processing

Assignment 2 实验报告 : Word2Vec (Skip-gram + Negative Sampling)

1. 实验目标

在 Shakespeare 语料上实现并训练 Word2Vec 的 Skip-gram + Negative Sampling 模型，并完成：

1. 数据处理与训练样本构建。
2. SkipGram 模型与损失函数实现。
3. 训练过程记录与损失下降趋势展示。
4. 两组超参数对比与词类比任务评估。
5. 词向量导出与降维可视化。

2. 数据与文件

- 训练语料：`shakespeare.txt`
- 评估文件：`questions-words-shakespeare.csv`
- 实现文件：`A2_w2v.ipynb`
- 报告文件：`report.md`

3. 方法实现

3.1 数据处理

实现了 `generate_data(words, window_size, k, corpus)` 与 `batchify(data, batch_size)`：

1. 对每个中心词提取窗口内上下文词作为正样本。
2. 使用 `corpus.getNegatives(...)` 采样负样本。
3. 组织为 `(center, outside, negatives)` 并批量张量化。

3.2 模型与损失

SkipGram 使用两套 embedding：`emb_v`（中心词）与 `emb_u`（上下文词）。

损失采用负采样目标：

$$L = -\log \sigma(u_o^T v_c) - \sum_{i=1}^k \log \sigma(-u_{n_i}^T v_c)$$

实现中对分数做 `clamp(-10, 10)` 以增强数值稳定性。

3.3 训练流程

`train(model, dataloader, optimizer, epochs)` 完成：

- 1. batch 级前向、反向与优化。
- 2. 按间隔打印近期平均 loss。
- 3. 返回 step 级损失序列用于绘图。

4. 实验设置（按评分建议）

本次评测采用 **Top-5** 词类比标准（**topn=5**），并按建议使用更强超参数：

- Set1
 - `emb_size = 150`
 - `k = 15`
 - `window_size = 5`
 - `epochs = 3`
 - `batch_size = 128`
 - `lr = 0.01`
 - `topn_eval = 5`
- Set2
 - `emb_size = 200`
 - `k = 20`
 - `window_size = 5`
 - `epochs = 3`
 - `batch_size = 128`
 - `lr = 0.008`
 - `topn_eval = 5`

两组均满足“same epochs”。

epochs 取 3 的简要理由：在当前设置下，loss 曲线已呈明显下降且第 3 轮后进入缓降区；同时 Top-5 analogy 准确率已达到评分要求（>1%）。因此本次采用 **epochs=3** 作为效果与训练成本的折中选择。

5. 结果与分析


5.1 词类比准确率（Top-5）

Set	emb_size	k	window_size	epochs	topn	Accuracy	Hit/Total
Set1	150	15	5	3	5	0.020492	15/732
Set2	200	20	5	3	5	0.021858	16/732

结论：两组都达到并超过 1%（Top-5）标准，Set2 略优。


5.2 损失曲线（Requirement 3a）

图 1：按 optimization step 的损失曲线



该图显示 loss 在前期快速下降，后期缓慢下降并趋稳，存在小幅抖动但总体单调下降趋势明显。这样只能看到总体趋势，但后面效果不明显，所以我们再以epoch为横坐标来画图。

图 2 : 按 epoch 的平均损失



观察到每个 epoch 的平均 loss 逐轮下降，进一步验证训练收敛趋势。

5.3 关于横轴选择（Requirement 3b 相关说明）

报告同时给出两种横轴是最完整的做法：

- 1. **Optimization step**：点更密，最能展示训练全过程下降趋势。
- 2. **Epoch**：更简洁，便于概览每轮平均损失变化。


因此本报告两图并列展示，满足趋势说明与可读性要求。

6. 词向量导出与可视化

已按 **gensim** 兼容格式导出：

- **embeddings_set1.txt**
- **embeddings_set2_ember.txt**
- **embeddings.txt**

用 **TruncatedSVD(n_components=2)** 对词向量降维，并对指定词（如 **sister, brother, woman, man, girl, boy, queen, king**）进行二维可视化得到如下图所示。



7. 总结

本实验完整实现了 Word2Vec Skip-gram + Negative Sampling 的训练与评估流程。在 Top-5 词类比标准下，两组设置均超过 1% 基准；同时，发现step 级与 epoch 级两类损失图均显示清晰下降趋势，满足要求。