

CS310 NLP Assignment 3 Report

Name: [莫丰源] Student ID: [12311805] Date: 2026-04-15

0. Summary

本实验完成了 A3 要求的三阶段流程：

1. 从 CLUECorpus2020 中文维基子集提取并预处理文本
2. 在该语料上从零训练 BPE tokenizer
3. 使用该 tokenizer 预训练 GPT-2 (124M 配置) 并记录训练曲线与损失

1) Data Extraction and Preprocess (5 pts)

脚本：

- [preprocess_wikizh.py](#)

实现细节：

- 按行读取 JSON
- 每行取 title 与 text 字段
- 将 title + text 拼接为一行输出
- 跳过异常 JSON

输出语料：

- [wikizh.txt](#)

统计：

- 处理文件数：1274 (AA-AL 各 100, AM 74)
- `wc -l wikizh.txt` = 9,569,010
- `wc -w wikizh.txt` = 9,605,215

2) Train Tokenizer From Scratch (5 pts)

脚本：

- [train_tokenizer_from_scratch.py](#)

配置：

- 模型：BPE
- pre-tokenizer：Whitespace
- vocab_size：52000
- min_frequency：2

Tokenizer 文件：

- [wikizh_tokenizer_whitespace.json](#)

- 现象说明:

- Readable 对比结果补充 (来自 compare_readable_output.txt):

- ## 2c) 使用训练 tokenizer 统计语料总 token 数

- `count_tokens_stream.py`

- total_lines: 9,569,010
- nonempty_lines: 5,338,162
- tokens: 256,609,695

- token_stats_full.json

3) Complete Pretraining Script (10 pts)

- run_pretrain.py

- global_step 与 tokens_seen 统计
- eval_freq 周期评估 (Train/Val loss)
- save_ckpt_freq 周期 checkpoint
- 最终模型与最终 checkpoint 保存
- loss curve 导出
- 100M token 里程碑检查 (target_tokens)
- 里程碑阈值检查 (target_val_loss=5.0)

- vocab size: 52000

- context_length: 1024
- emb_dim: 768
- n_heads: 12
- n_layers: 12
- drop_rate: 0.1
- qkv_bias: False

4) Pretraining and Results (10 pts)

训练参数:


- batch_size: 8
- epochs: 3
- train/val split: 0.9/0.1
- initial lr: 1e-4
- eval_freq: 100
- save_ckpt_freq: 5000
- data_fraction: 0.16
- warmup_steps: 1200
- min_lr_ratio: 0.2

当前训练结果:

- 最后一次记录 (job 76216, step 30,900):
 - Train loss: 4.3837
 - Val loss: 4.8747
 - Tokens seen: 253,132,800
- 最低观测 Val loss: 约 4.8741 (step 30,800)

最终产物 (来自 job.76216.out):

- [model_checkpoints_best/checkpoint_final.pth](#)
- [model_checkpoints_best/model_final.pth](#)



- 训练总时长：09:27:39
- 峰值显存：27.97 GB

验收结论：

- 已满足目标：在 76216 实验中，Val loss 下降至 < 5.0 （最低约 4.8741），通过该项标准。

训练补充经验：

- 在 76404 调参阶段，曾出现训练 loss 进入平台期、下降停滞的问题；后续通过调整训练参数后，正式实验（76216）达到更低 Val loss 并满足目标。

Reproducibility Commands

```
python preprocess_wikizh.py \  
  --input "wiki_zh_2019/wiki_zh" \  
  --output "wikizh.txt"  
  
python train_tokenizer_from_scratch.py \  
  --input "wikizh.txt" \  
  --vocab_size 52000 \  
  --pre_tokenizer Whitespace \  
  --output "wikizh_tokenizer_whitespace.json"  
  
python run_pretrain.py \  
  --data_file "wikizh.txt" \  
  --tokenizer "wikizh_tokenizer_whitespace.json" \  
  --output_dir "model_checkpoints" \  
  --n_epochs 1 \  
  --eval_freq 100 \  
  --save_ckpt_freq 1000 \  
  --lr 1e-4 \  
  --batch_size 4 \
```

```
--train_ratio 0.9 \
--vocab_size 52000 \
--target_tokens 100000000 \
--target_val_loss 5.0
```

Submission Checklist

- ☒ `run_pretrain.py` 完成
- ☒ `wikizh_tokenizer_whitespace.json` 已有
- ☒ token 全量统计结果已给出 (256,609,695)
- ☒ `compare_tokenizers` 输出已生成 (见 `compare_output_offline_job.txt`)
- ☒ 正式 full-run 模型与 loss 曲线已生成 (job 76216)

Evidence Files

1. Requirement 1 预处理统计

- 终端输出: `python preprocess_wikizh.py` 与 `wc -l wikizh.txt`、`wc -w wikizh.txt`

2. Requirement 2b 对比输出

- [job.76136.out](#)
- [job.76138.out](#)
- [compare_output_offline_job.txt](#)
- [compare_readable_output.txt](#)

3. Requirement 2c token 总数

- [token_stats_full.json](#)

4. Requirement 4 训练过程与结果

```
Epoch 3/3 | Step 30,100 | Train loss 4.3875 | Val loss 4.8806 | Tokens seen 246,579,200
Epoch 3/3 | Step 30,200 | Train loss 4.3258 | Val loss 4.8800 | Tokens seen 247,398,400
Epoch 3/3 | Step 30,300 | Train loss 4.4242 | Val loss 4.8807 | Tokens seen 248,217,600
Epoch 3/3 | Step 30,400 | Train loss 4.4677 | Val loss 4.8793 | Tokens seen 249,036,800
Epoch 3/3 | Step 30,500 | Train loss 4.3846 | Val loss 4.8792 | Tokens seen 249,856,000
Epoch 3/3 | Step 30,600 | Train loss 4.3445 | Val loss 4.8760 | Tokens seen 250,675,200
Epoch 3/3 | Step 30,700 | Train loss 4.4433 | Val loss 4.8762 | Tokens seen 251,494,400
Epoch 3/3 | Step 30,800 | Train loss 4.3065 | Val loss 4.8741 | Tokens seen 252,313,600
Epoch 3/3 | Step 30,900 | Train loss 4.3837 | Val loss 4.8747 | Tokens seen 253,132,800
Training finished in 09:27:39
Saved final checkpoint: model_checkpoints_best/checkpoint_final.pth
Saved loss curve: model_checkpoints_best/loss_curve.pdf
Saved final model: model_checkpoints_best/model_final.pth
Maximum GPU memory allocated: 27.97 GB
Training completed!
```

- [model_checkpoints_best/model_final.pth](#)

