

CS310 NLP Assignment 3 Report

Name: [莫丰源] Student ID: [12311805] Date: 2026-04-18

1) Data Extraction and Preprocess (5 pts)

脚本：

- [preprocess_wikizh.py](#)

实现细节：

- 按行读取 JSON
- 每行取 title 与 text 字段
- 将 title + text 拼接为一行输出
- 跳过异常 JSON

输出语料：

- [wikizh.txt](#)

统计：

- 处理文件数：1274 (AA-AL 各 100, AM 74)
- `wc -l wikizh.txt` = 9,569,010
- `wc -w wikizh.txt` = 9,605,215

2) Train Tokenizer From Scratch (5 pts)

脚本：

- [train_tokenizer_from_scratch.py](#)

配置：

- 模型：BPE
- pre-tokenizer：Whitespace
- vocab_size：52000
- min_frequency：2

Tokenizer 文件：

- [wikizh_tokenizer_whitespace.json](#)

2b) compare_tokenizers 输出

脚本：

- [compare_tokenizers.py](#)

执行情况：

- 证据文件:

•

- [job.76138.out](#) (离线 compare 专用任务日志)

●

●

- 训练 tokenizer 能把中文按词/短语切分 (例如“太阳”“照”“常”“升起”)
- 原始 GPT-2 tokenizer 对中文切分碎片化更明显

- 原始 GPT-2 使用 byte-level BPE；对中文常会切成多个字节片段。
- 当把这些“单个片段 token”分别解码时，可能显示为替换符号（如 ）或看似乱码。
- 这属于 tokenizer 机制差异，不是程序报错。完整序列解码仍可恢复原句语义。

Readable 对比结果补充 (来自 compare_readable_output.txt):

- 输入：太阳照常升起。
- 新训练 tokenizer：['太阳', '照', '常', '升起', '。']
- 原始 GPT-2 raw tokens：['â', 'â', 'é', 'í', '³', 'ç', 'h', '§', 'â', 'â', 'â', 'î', 'è', 'µ', 'â', 'ã']
- 该结果进一步说明：新 tokenizer 对中文切分更符合词级语义，而原始 GPT-2 更偏字节片段。

2c) 使用训练 tokenizer 统计语料总 token 数

为避免大文件内存问题，使用新增脚本流式统计：

- count_tokens_stream.py

全量统计结果 (token_stats_full.json):

- total_lines: 9,569,010
- nonempty_lines: 5,338,162
- tokens: 256,609,695

结果文件：

- token_stats_full.json

3) Complete Pretraining Script (10 pts)

脚本：

- run_pretrain.py

4) Pretraining and Results (10 pts)

训练参数：

- batch_size: 4
- epochs: 1
- train/val split: 0.9/0.1
- initial lr: $2.5e-4$
- eval_freq: 100
- save_ckpt_freq: 1000
- data_fraction: 0.5
- warmup_steps: 3600
- min_lr_ratio: 0.2
- eval_iter: 8
- drop_rate: 0.1
- vocab_size: 52000
- target_tokens: 1,000,000,000
- target_val_loss: 5.0
- no_stop_at_target_tokens: True
- no_enforce_target: True
- max_grad_norm: 1.0

- weight_decay: 0.05


当前训练结果：

- 最后一次记录：
 - Train loss: 4.3471
 - Val loss: 4.1380
 - Tokens seen: 251,084,800
- 最低观测 Val loss：约 4.1372（step 61,100）

```
754 Epoch 1/1 | Step 60,100 | Train loss 4.2225 | Val loss 4.1533 | Tokens seen 246,169,600
755 Epoch 1/1 | Step 60,200 | Train loss 4.2014 | Val loss 4.1474 | Tokens seen 246,579,200
756 Epoch 1/1 | Step 60,300 | Train loss 4.2732 | Val loss 4.1466 | Tokens seen 246,988,800
757 Epoch 1/1 | Step 60,400 | Train loss 4.1626 | Val loss 4.1546 | Tokens seen 247,398,400
758 Epoch 1/1 | Step 60,500 | Train loss 4.3897 | Val loss 4.1462 | Tokens seen 247,808,000
759 Epoch 1/1 | Step 60,600 | Train loss 4.2999 | Val loss 4.1447 | Tokens seen 248,217,600
760 Epoch 1/1 | Step 60,700 | Train loss 4.3299 | Val loss 4.1411 | Tokens seen 248,627,200
761 Epoch 1/1 | Step 60,800 | Train loss 4.3690 | Val loss 4.1385 | Tokens seen 249,036,800
762 Epoch 1/1 | Step 60,900 | Train loss 4.3144 | Val loss 4.1350 | Tokens seen 249,446,400
763 Epoch 1/1 | Step 61,000 | Train loss 4.1902 | Val loss 4.1426 | Tokens seen 249,856,000
764 Saved checkpoint: model_checkpoints_opt/checkpoint_step_61000.pth
765 Epoch 1/1 | Step 61,100 | Train loss 4.2976 | Val loss 4.1372 | Tokens seen 250,265,600
766 Epoch 1/1 | Step 61,200 | Train loss 4.1338 | Val loss 4.1410 | Tokens seen 250,675,200
767 Epoch 1/1 | Step 61,300 | Train loss 4.3471 | Val loss 4.1380 | Tokens seen 251,084,800
768 Training finished in 09:11:16
769 Saved final checkpoint: model_checkpoints_opt/checkpoint_final.pth
770 Saved loss curve: model_checkpoints_opt/loss_curve.pdf
771 Saved final model: model_checkpoints_opt/model_final.pth
772 Maximum GPU memory allocated: 15.73 GB
773 Training completed!
```

最终产物（来自 job.76216.out）：

- [model_checkpoints_best/checkpoint_final.pth](#)
- [model_checkpoints_best/model_final.pth](#)



- 训练总时长：09:11:16
- 峰值显存：15.73 GB

Experiment Summary

本次 A3 实验完整实现了中文维基语料的预处理、BPE 分词器的从零训练，以及基于自定义分词器的 GPT-2 预训练。通过流式脚本高效统计了大规模 token 数量，分词器对中文的切分效果显著优于原始 GPT-2。预训练阶段采用优化器脚本，合理调整了 batch size、学习率、warmup、梯度裁剪等参数，最终在 2.5 亿 token 规模下，模型收敛良好，验证集 loss 降至 4.14 左右，显存与训练时长均在可控范围。实验产物齐全，流程可复现，充分展示了中文大模型预训练的关键技术路径与工程实现能力。