

Assignment 5: DPO for LLM Human Alignment

学生姓名：莫丰源 日期：2026年5月19日

1. 实验目标

本实验的目标是使用 **Direct Preference Optimization (DPO)** 方法，对已完成监督微调 (SFT) 的 GPT-2 medium (355M) 模型进行人类偏好对齐。

实验使用提供的 `instruction-data-with-preference.json` 数据集（约 1000 个样本）进行 1 个 epoch 的训练，并完成以下任务：

- 跟踪训练过程中的损失 (Loss) 与奖励边际 (Reward Margin)；
- 保存完成对齐后的模型；
- 在 AlpacaEval 基准上进行评估；
- 与未进行 DPO 对齐的 SFT 参考模型进行效果对比。

2. 代码实现

本实验完整实现了 `run_dpo.py`，并在实验提供代码的基础上进行了必要扩展。

2.1 数据处理

实现了以下模块：

- `PreferenceDataset` 类；
- `custom_collate_fn` 函数；
- Prompt Masking 机制。

2.2 DPO 核心函数

实现了以下关键函数：

- `compute_dpo_loss`
- `compute_logprobs`
- `compute_dpo_loss_batch`

2.3 训练流程

实现了 `train_model_dpo_simple` 作为主要训练循环。

训练过程中：

- `policy_model` 处于 `.train()` 模式，并使用 AdamW 优化器进行参数更新；
- `reference_model` 处于 `.eval()` 模式，并冻结参数；

- 同时跟踪训练集与验证集的：
 - Loss
 - Reward Margin (chosen_reward - rejected_reward)

2.4 主要超参数

超参数	数值
β	0.1
Learning Rate	5e-6
Batch Size	8
Evaluation Interval	每 10 步


脚本已在可用硬件环境中成功运行，并生成所需训练曲线。

3. 训练结果

模型完成了 **1 个 epoch** 的训练，在 A100 GPU 上训练时间约为 2~3 分钟。


训练结果表明模型具有明显的偏好优化效果。

3.1 训练损失曲线



训练损失与验证损失均呈稳定下降趋势，说明模型优化过程有效且收敛正常。

3.2 奖励边际曲线



训练集与验证集的奖励边际均持续上升，说明模型逐渐学会为“chosen（偏好）”回答赋予更高概率，而降低“rejected（非偏好）”回答的概率。

3.3 训练结束后的关键统计

指标	数值
最终训练损失	≈ 0.563
最终验证损失	≈ 0.615
训练奖励边际	> 3.0
验证奖励边际	≈ 1.8

整体训练曲线符合实验预期。

4. 模型生成与 AlpacaEval 评估

使用提供的 `generate_dpo_response.py` 脚本，在 AlpacaEval 测试集上生成模型回答，并成功得到格式正确的 `model_outputs.json` 文件。

随后使用 Qwen Judge 进行评估：

```
OPENAI_CLIENT_CONFIG_PATH='/path/to/your/openai_configs.yaml'
alpaca_eval evaluate \
  --model_outputs 'model_outputs.json' \
  --reference_outputs 'reference_outputs.json' \
  --annotators_config '/full/path/to/qwen_judge'
```

4.1 评估结果

	length_controlled_winrate	win_rate	standard_error	n_total	avg_length
gpt2-medium355M-dpo.pth	78.15	59.84	1.59	805	56

主要指标

指标	数值
Length-controlled Win Rate	78.15%
Raw Win Rate	59.84%
Standard Error	1.59
样本总数	805
平均回答长度	56

DPO 对齐后的模型显著优于未对齐的 SFT 参考模型。

其中：

- 胜率明显高于 50%；
- Length-controlled Win Rate 达到 78.15%；
- 证明了 DPO 在 GPT-2 medium 模型上的人类偏好对齐效果。

5. 实验总结

本次实验成功完成了 DPO 用于 LLM 人类偏好对齐的实现。

从训练过程来看：

- Loss 稳定下降；
- Reward Margin 持续上升；
- 模型优化过程稳定。

最终模型在 AlpacaEval 上取得了 **78.15% 的 Length-controlled Win Rate**，验证了 DPO 方法在语言模型对齐任务中的有效性。

总体而言，本实验加深了对以下内容的理解：

- DPO 的核心思想；
- 偏好学习的训练机制；
- 人类对齐在大语言模型中的实际应用。